UNIVERSIDADE CATÓLICA DO SALVADOR
CURSO DE BACHARELADO EM ENGENHARIA DE SOFTWARE

LUCAS ALVES MATOS SAMPAIO GASPARI
WALTER QUEIROZ ROCHA
GUILHERME FERREIRA SAMPAIO

UNIFICAÇÃO, TRATAMENTO, MODELAGEM, ARMAZENAMENTO E INFRAESTRUTURA DOS DADOS

Tema: Auditoria de Viés Étnico-Gênero em Fomento à Pesquisa Científica

Salvador
2026

LUCAS ALVES MATOS SAMPAIO GASPARI
WALTER QUEIROZ ROCHA
GUILHERME FERREIRA SAMPAIO

UNIFICAÇÃO, TRATAMENTO, MODELAGEM, ARMAZENAMENTO E INFRAESTRUTURA DOS DADOS

Tema: Auditoria de Viés Étnico-Gênero em Fomento à Pesquisa Científica

Trabalho apresentado à disciplina Big Data e Analytics do curso de Bacharelado em Engenharia de Software da Universidade Católica do Salvador, como entrega técnica da fase 2.

Salvador
2026

1 INTRODUÇÃO

Esta fase preparou a base definida na etapa anterior. Os dados de 2019 a 2024 foram tratados, unificados a partir de duas fontes do CNPq e armazenados em um PostgreSQL no Aiven, com a infraestrutura descrita em Terraform. Todo o código, a base tratada e a documentação estão no repositório `https://github.com/Caspiom/Trabalho-big-data`, e o `README.md` traz o passo a passo de execução.

Durante a preparação, verificou-se que o CSV exportado do painel não traz sexo nem raça ou cor, que são as dimensões centrais da auditoria. Por isso, o CSV foi unificado com um extrato agregado do próprio painel, que contém essas informações.

2 BASE DE DADOS TRATADA

2.1 Origem e versão original

As duas fontes vêm do Painel de Demanda e Atendimento do CNPq, que utiliza dados da Plataforma Integrada Carlos Chagas. O recorte é feito pelo ano da chamada (`ano_chamada`), de 2019 a 2024, e pelas linhas de bolsas no país, bolsas no exterior e apoio a projetos de pesquisa.

Quadro 1 – Origem e versão original dos dados

Fonte	**Conteúdo**	**Versão original utilizada**
CSV de dados abertos (`Base_CNPq_Demanda_Atendimento_2019_2024.csv`)	Uma linha por processo: chamada, modalidade, área, instituição, região, valores e situação. Não tem sexo nem raça ou cor	100.693.334 bytes, 142.222 linhas e 39 colunas, separador “;”. SHA-256: `18d9dfddd734ffca2db1310a6e3eaad1cf2a7c2d8af57918a53e525f9da09120`
Relatório Power BI do painel	Mesmo cadastro, com sexo e raça ou cor, em totais por grupo	Extrato com 57.656 combinações e 13 colunas, salvo sem tratamento em `data/raw`

Fonte: Elaboração própria (2026).

2.2 Versão resultante

A versão tratada está em `data/processed` e é exatamente a que foi carregada no banco. Executar o tratamento de novo sobre o mesmo CSV gera arquivos idênticos.

Quadro 2 – Versão resultante após o tratamento

Arquivo	Conteúdo	Linhas
`fato_atendimento_grupo.csv`	Painel agregado por ano, sexo, raça ou cor, grande área, linha de fomento, modalidade e região	9.173
`fato_atendimento_csv.csv`	CSV agregado pelas mesmas dimensões, sem sexo e raça ou cor	1.397
`processo_tratado.csv`	Um processo por linha, já tratado, sem sexo e raça ou cor	139.761
`dim_*.csv`	Grande área, linha de fomento, modalidade e região padronizadas	11, 3, 13 e 7
`log_tratamento.csv`	Quantidade de linhas afetadas por cada regra	44

Fonte: Elaboração própria (2026).

3 PROCESSO DE TRATAMENTO DOS DADOS

O processo foi desenvolvido em Python 3.14, com pandas para o tratamento, requests para a extração e pg8000 para a carga. São três scripts executados em sequência, que reconstroem a base inteira a partir das fontes.

Quadro 3 – Scripts do processo

Script	Função
`extrair_painel.py`	Consulta o painel ano a ano e salva o extrato agregado por sexo e raça ou cor
`tratar.py`	Filtra, padroniza, remove duplicados e reenvios, corrige valores, agrega e gera as dimensões comuns
`carregar.py`	Recria as tabelas, carrega os arquivos tratados com `COPY` e libera leitura ao usuário de análise

Fonte: Elaboração própria (2026).

As etapas de tratamento foram:

- leitura do CSV em blocos, com todos os campos como texto;
- padronização de grafias de cidade, UF, instituição e categorias, comparando por uma chave sem acento, caixa e pontuação;
- validação da UF contra a lista oficial e correção da região a partir da UF;
- dedução da modalidade vazia pelas outras edições da mesma chamada e correção da grande área pela classificação predominante da área;
- recorte de 2019 a 2024 e seleção das linhas de bolsas e auxílios à pesquisa;
- remoção de duplicados exatos e de reenvios da mesma proposta;
- conversão de tipos e correção de valores zerados, com vírgula deslocada ou implausíveis;
- agregação das duas fontes pelas mesmas dimensões.

Quadro 4 – Quantidade de linhas por etapa

Etapa	Painel	CSV
Linhas lidas	57.656	142.222
Sem números de processo repetidos	–	142.222
Recorte de 2019 a 2024	57.656	142.222
Somente bolsas e auxílios	53.340	139.999
Sem duplicados exatos (14) e reenvios (224)	–	139.761
Após agregação	9.173	1.397

Fonte: Elaboração própria (2026).

O CSV já vinha restrito ao período, então o tratamento atuou mais nas colunas e nos valores do que no número de linhas: 33.985 grafias de cidade e 48.897 de nome de UF foram unificadas, 14.136 modalidades vazias foram deduzidas e 6.250 siglas de instituição foram padronizadas. A tabela de processos ficou com 14 das 39 colunas, e o arquivo de 100 MB caiu para 16,4 MB. Foram criados 45 testes automatizados em Python e 4 testes do Terraform, todos aprovados.

4 DECISÕES TÉCNICAS E JUSTIFICATIVAS

Quadro 5 – Decisões técnicas

Decisão	Justificativa
Sexo e raça ou cor extraídos somente de forma agregada	Raça ou cor é dado pessoal sensível (LGPD, art. 5º, II) e a auditoria compara grupos, sem precisar de registros individuais
Unificação das fontes por dimensões comuns	Ano, grande área, linha de fomento, modalidade e região permitem comparar e reconciliar as duas bases
Uso de `nme_chamada_macro` como linha de fomento	A coluna `nme_linha_fomento` tinha valor inválido em 85,9% das linhas
Somente bolsas no país, bolsas no exterior e apoio a projetos	São as linhas definidas na Etapa 1; a chamada ARC, eventos e prêmios ficam de fora
Leitura com parser CSV e campos como texto	Títulos e palavras-chave contêm ponto e vírgula, o que deslocaria colunas
Grafias unificadas pela forma acentuada mais frequente	Junta variações como “SAO PAULO” e “São Paulo” sem juntar nomes diferentes
Erros de UF corrigidos só contra a lista oficial	Evita “corrigir” um valor certo para outro valor errado da própria base
Reenvios removidos, mantendo o atendido ou o último	A mesma proposta submetida duas vezes inflaria a demanda
Valor zero tratado como nulo; vírgula deslocada corrigida; implausível como nulo	Ninguém pede R$ 0, e um valor mil vezes acima da mediana distorceria os totais

(continua)

(continuação)

Decisão	Justificativa
Valor atendido maior que o demandado mantido	Pode ocorrer de forma legítima; excluir alteraria os totais
“Não desejo declarar” e ausentes como “Não informado”	Mantidos como categoria própria, sem redistribuir entre grupos
Taxa de atendimento calculada no banco	Coluna gerada garante que a taxa sempre corresponda às quantidades
Diferença entre grupos calculada em view	Usa homens brancos, o maior grupo, como referência, sem alterar os dados
Sem amostragem	Grupos pequenos ficariam instáveis
Carga em uma transação, com certificado validado	Uma falha não deixa o banco pela metade e a conexão é protegida

Fonte: Elaboração própria (2026).

5 BASE ARMAZENADA EM BANCO DE DADOS

Os dados estão em um PostgreSQL 17 no Aiven, em um modelo dimensional: duas tabelas fato que compartilham quatro dimensões (constelação de fatos) e uma tabela de processos. O modelo foi escolhido porque a auditoria consulta medidas recortadas por categorias, e as dimensões compartilhadas garantem que as duas fontes usem os mesmos nomes. Cada tabela tem quatro chaves estrangeiras, uma para cada dimensão, em relacionamentos de um para muitos. Carregado no Aiven, o banco ocupa 32 MB, cerca de 5% da meta de 650 MB da Etapa 1.

Figura 1 – Modelo dimensional: tabelas à esquerda, dimensões à direita

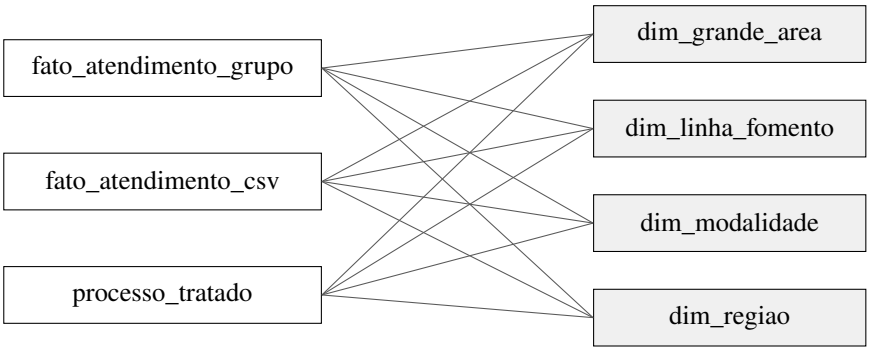

Cada linha é uma chave estrangeira, em relação de um (dimensão) para muitos (tabela).

Fonte: Elaboração própria (2026).

Quadro 6 – Tabelas, campos e quantidade armazenada

Tabela	Principais campos e tipos	Registros
fato_atendimento_grupo	ano SMALLINT; sexo VARCHAR(20); raça ou cor VARCHAR(30); 4 chaves SMALLINT; quantidades INTEGER; valores NUMERIC(16,2); taxa NUMERIC(7,4) gerada	9.173
fato_atendimento_csv	Mesmos campos, sem sexo, raça ou cor e taxa	1.397
processo_tratado	nu_processo VARCHAR(20) chave primária; ano; 4 chaves; UF CHAR(2); cidade, sigla, instituição e país; atendido BOOLEAN; valores NUMERIC(16,2)	139.761
dim_*	id SMALLSERIAL; nome VARCHAR único	11, 3, 13 e 7
vw_diferenca_grupo (view)	Taxa por ano, área, sexo e raça ou cor e diferença para o grupo de referência	740
vw_reconciliacao_fontes (view)	Totais do painel e do CSV por ano, área e linha de fomento	137

Fonte: Elaboração própria (2026).

6 INFRAESTRUTURA

A infraestrutura está descrita como código em `infra/terraform`, com o provider oficial do Aiven. O plano gratuito (`free-1-1gb`: 1 CPU, 1 GB de RAM e 1 GB de disco) foi escolhido porque não tem prazo nem exige cartão, o que mantém o custo do projeto em zero. O Aiven só cria serviços gratuitos na DigitalOcean e na UpCloud, sem região na América do Sul, então a região padrão é `do-nyc` (Nova York), a mais próxima.

Quadro 7 – Recursos provisionados pelo Terraform

Recurso	Função
aiven_pg.banco	Serviço PostgreSQL 17, com filtro de IP e etiquetas do projeto
aiven_pg_database.fomento	Banco fomento_cnpq, separado do banco padrão
random_password.leitura	Senha de 24 caracteres do usuário de leitura, sorteada pelo Terraform
aiven_pg_user.leitura	Usuário analise_leitura, para as próximas fases
local_sensitive_file.env e .ca	Grava o .env (permissão 0600) e o certificado ca.pem que o ETL usa

Fonte: Elaboração própria (2026).

A região foi colocada em `ignore_changes` porque o Aiven pode mover serviços gratuitos de região; sem isso, o Terraform tentaria migrar o banco de volta. Os testes do Terraform usam providers simulados, então verificam o plano sem precisar de conta. Um workflow do GitHub Actions roda os testes Python, valida o Terraform e procura segredos a cada envio ao

repositório.

7 SEGURANÇA DAS INFORMAÇÕES

Nenhuma credencial está no repositório. O token da API do Aiven fica apenas na variável de ambiente `AIVEN_TOKEN` de quem executa o Terraform, lida sem eco no terminal. As senhas do banco não são escolhidas nem digitadas por ninguém: a do administrador vem do Aiven, a do usuário de leitura é sorteada pelo Terraform, e as duas vão direto para o `.env` local, que o script de carga lê.

Quadro 8 – Tratamento das credenciais

Medida	**Como foi aplicada**
Arquivos sensíveis fora do Git	`.gitignore` cobre `.env`, certificados, `*.tfstate` e `*.tfvars`; o repositório só tem modelos sem valores
Saídas sensíveis	URLs de conexão marcadas como `sensitive` no Terraform, sem aparecer no `plan`
Conexão protegida	TLS com verificação do certificado e do nome do servidor pelo `ca.pem` do projeto
Menor privilégio	Usuário de análise só com `SELECT`; testes confirmam que ele não altera dados nem cria tabelas
Varredura de segredos	gitleaks no histórico completo; a única ocorrência é a chave pública do painel Power BI, publicada pelo próprio CNPq
Plano de resposta	Revogar o token, recriar o usuário com `-replace` ou redefinir a senha no console

Fonte: Elaboração própria (2026).

8 LIMITAÇÕES

O painel cobre mais processos que o CSV: 184.794 propostas contra 139.761 no período. A diferença fica registrada na view de reconciliação, sem ajuste artificial. A auditoria usa o painel, que é a fonte com sexo e raça ou cor. Além disso, a consulta ao painel depende de uma interface não documentada; por isso o extrato original fica salvo no repositório. No plano gratuito não há alta disponibilidade, e o serviço pode ser desligado por falta de uso.

REFERÊNCIAS

AIVEN. **Aiven for PostgreSQL free tier**. 2026. Disponível em: `https://aiven.io/docs/products/postgresql/concepts/pg-free-tier`. Acesso em: 20 set. 2026.

AIVEN. **Aiven Provider for Terraform**. 2026. Disponível em: `https://registry.terraform.io/providers/aiven/aiven/latest/docs`. Acesso em:

31 out. 2026.

BRASIL. **Lei nº 13.709, de 14 de agosto de 2018**. Lei Geral de Proteção de Dados Pessoais. Brasília, DF, 2018.

CNPQ. **Painel de Demanda e Atendimento**. Brasília, DF, 2026. Disponível em: https://www.gov.br/cnpq/pt-br/acesso-a-informacao/dados-abertos/paineis-de-dados/painel-de-demanda-e-atendimento. Acesso em: 8 out. 2026.

SAMPAIO, G. F.; GASPARI, L. A. M. S.; ROCHA, W. Q. **Levantamento de parâmetros e tipagem de dados**. Salvador: UCSAL, 2026. Trabalho da disciplina Big Data e Analytics.

HASHICORP. **Terraform tests**. 2026. Disponível em: https://developer.hashicorp.com/terraform/language/tests. Acesso em: 31 out. 2026.

KIMBALL, R.; ROSS, M. **The data warehouse toolkit**: the definitive guide to dimensional modeling. 3. ed. Indianapolis: Wiley, 2013.

UCSAL. **Guia de orientação do projeto prático**: Big Data. Salvador: Universidade Católica do Salvador, 2026. Material da disciplina.